RAG là gì?

RAG (Retrieval-Augmented Generation) là kiến trúc kết hợp truy xuất tài liệu với mô hình ngôn ngữ lớn. Thay vì để LLM trả lời hoàn toàn từ tham số đã học, hệ thống tìm các đoạn văn bản liên quan trong kho tri thức rồi đưa chúng vào ngữ cảnh của prompt. Nhờ vậy câu trả lời bám sát tài liệu và có thể trích dẫn nguồn.

Ba thành phần chính của RAG:
1. Kho tri thức: tài liệu đã được chia nhỏ thành chunk và chuyển thành embedding.
2. Bộ truy xuất: tìm top-k chunk gần câu hỏi nhất.
3. Mô hình sinh: tạo câu trả lời chỉ từ ngữ cảnh được cung cấp.

RAG phù hợp khi kiến thức thay đổi thường xuyên hoặc khi cần dẫn nguồn. Fine-tuning phù hợp hơn khi cần thay đổi phong cách, định dạng đầu ra, hoặc dạy một kỹ năng mới cho mô hình.

Pipeline RAG gồm hai pha

Pha ngoại tuyến (ingest):
- Trích xuất text từ PDF theo từng trang.
- Chia văn bản thành chunk có overlap.
- Tạo embedding cho từng chunk.
- Lưu vector và metadata (tên file, số trang) vào vector store.

Pha truy vấn (query):
- Chuyển câu hỏi thành embedding bằng cùng mô hình.
- Tìm top-k chunk có cosine similarity cao nhất.
- Lọc theo ngưỡng liên quan tối thiểu.
- Ghép ngữ cảnh và câu hỏi thành prompt có ràng buộc.
- Gọi LLM, nhận câu trả lời và gắn trích dẫn nguồn.

Trong project này, top-k mặc định là 4 và ngưỡng liên quan mặc định là 0.18. Hai tham số này được đo ở Tuần 5, không chọn theo cảm tính.

Chunking và các tham số quan trọng

Chunk là một đoạn văn bản nhỏ được truy xuất độc lập. Chunk quá nhỏ làm mất ngữ cảnh; chunk quá lớn chứa nhiều thông tin nhiễu và tốn token.

Kích thước mặc định trong project là 700 ký tự với overlap 120 ký tự. Overlap giúp câu trả lời không bị cắt đôi ở ranh giới hai chunk.

Top-k ảnh hưởng trực tiếp:
- Top-k nhỏ (1-2): nhanh, ít nhiễu, nhưng dễ bỏ sót bằng chứng.
- Top-k lớn (8-10): tăng recall, nhưng prompt dài, chậm và dễ làm LLM lạc đề.

Chiến lược tốt là đo Hit Rate@k và Recall@k trên bộ câu hỏi cố định trước khi tăng k.

Giới hạn của RAG và cách đánh giá

RAG không loại bỏ hoàn toàn hallucination. LLM vẫn có thể diễn giải sai ngữ cảnh, bỏ qua bằng chứng, hoặc trả lời tự tin khi ngữ cảnh mơ hồ.

Các giới hạn thường gặp:
- PDF scan không có lớp text: cần OCR trước.
- Bảng biểu phức tạp bị trích xuất sai thứ tự.
- Câu hỏi mơ hồ khiến retrieval lấy sai chunk.
- Tài liệu dài vượt context window.

Thước đo retrieval:
- Hit Rate@k: tỷ lệ câu hỏi có ít nhất một nguồn đúng trong top-k.
- Recall@k: tỷ lệ nguồn đúng được tìm thấy trên tổng số nguồn đúng.
- MRR: nghịch đảo thứ hạng của nguồn đúng đầu tiên.

Thước đo câu trả lời: độ đúng so với đáp án tham chiếu, tỷ lệ trích dẫn đúng, và tỷ lệ từ chối đúng khi không có bằng chứng.